Análisis Estadístico de Datos

Taller 1

Grupo 3: Vanessa Ochoa, Juan Zamora y Nilson Amaya

8 de marzo de 2026

Contents

1 Introducción **2**

2 Parte 1. Fundamenos estadísticos **2**

2.1 Pregunta 1. 2

2.2 Pregunta 2. 3

2.3 Pregunta 3. 4

2.4 Pregunta 4. 4

2.5 Pregunta 5. 5

2.6 Pregunta 6. 5

2.7 Pregunta 7. 6

2.8 Pregunta 8. 7

2.9 Pregunta 9. 7

3 Parte 2. Estimación de la densidad **8**

3.1 Pregunta 10. 8

3.2 Pregunta 11. 9

3.3 Pregunta 12. 10

1 Introducción

El presente informe corresponde al desarrollo del Taller 1 del curso de Análisis Estadístico de Datos, en el cual se realiza un ejercicio de exploración y análisis estadístico a partir de información meteorológica recopilada en diferentes regiones de Colombia.

Para el desarrollo del taller se utiliza la base de datos ORI.csv, la cual contiene registros de variables climáticas medidas en distintos municipios del país.El objetivo de este taller es aplicar herramientas de análisis estadístico y visualización de datos utilizando el lenguaje R, con el fin de explorar el comportamiento de las variables meteorológicas, identificar patrones relevantes y evaluar posibles relaciones entre ellas.

Cargue de librerias necesarias

2 Parte 1. Fundamenos estadísticos

2.1 Pregunta 1.

Importe la base de datos a R y determine el número de UE y de variables en la base de datos. ¿Cuántas filas y cuántas columnas tiene la tabla?, ¿Cuántos registros fueron medidos o recolectados a medio día (hora = 12:00)?

```
ORI <- read_delim(
  "input/ORI.csv",
  delim = ";",
  locale = locale(encoding = "UTF-8")
) %>% clean_names()
```

```
## Rows: 4543 Columns: 18
## -- Column specification --------------------------------------------------------
## Delimiter: ";"
## chr   (5): Region, Departamento, Municipio, Fecha, Pronostico
## dbl  (12): Cod_Div, Latitud, Longitud, Temperatura, Velocidad_del_Viento, Di...
## time  (1): Hora
##
## i Use `spec()` to retrieve the full column specification for this data.
## i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
str(ORI)
```

```
## spc_tbl_ [4,543 x 18] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
##  $ cod_div                 : num [1:4543] 5e+07 5e+07 5e+07 5e+07 5e+07 ...
##  $ latitud                 : num [1:4543] 3.99 3.99 3.99 3.99 3.99 ...
##  $ longitud                : num [1:4543] -73.8 -73.8 -73.8 -73.8 -73.8 ...
##  $ region                  : chr [1:4543] "ORI" "ORI" "ORI" "ORI" ...
##  $ departamento            : chr [1:4543] "META" "META" "META" "META" ...
##  $ municipio               : chr [1:4543] "ACAC\xcdAS" "ACAC\xcdAS" "ACAC\xcdAS" "ACAC\xcdAS" ...
##  $ fecha                   : chr [1:4543] "25/08/2022" "25/08/2022" "25/08/2022" "25/08/2022" ...
##  $ hora                    : 'hms' num [1:4543] 16:00:00 17:00:00 18:00:00 19:00:00 ...
##   ..- attr(*, "units")= chr "secs"
##  $ temperatura             : num [1:4543] 26.5 25.6 24.1 23.4 22.8 22.2 21.3 21 21 21.1 ...
##  $ velocidad_del_viento    : num [1:4543] 1.5 0.9 1.7 1.8 2.2 2.2 2.3 2.5 2.3 2.3 ...
##  $ direccion_del_viento    : num [1:4543] 160 226 300 310 310 ...
```

```
##  $ presion                 : num [1:4543] 1013 1013 1014 1015 1015 ...
##  $ punto_de_rocio          : num [1:4543] 21.2 22.2 21.7 21.2 20.3 19.6 18.5 18 17.7 17.6 ...
##  $ cobertura_total_nubosa  : num [1:4543] 70 70 70 63.7 60.1 70 70 70 70 70 ...
##  $ precipitacion_mm_h      : num [1:4543] 0 0 0 0 0 0 0 0 0 0 ...
##  $ probabilidad_de_tormenta: num [1:4543] 0 0 0 0 0 0 0 0 0 0 ...
##  $ humedad                 : num [1:4543] 72.7 81.5 86.5 87.1 85.9 85.4 84 82.6 81.3 80.2 ...
##  $ pronostico              : chr [1:4543] "Parcialmente Nublado" "Parcialmente Nublado" "Parcialmente
##  - attr(*, "spec")=
##   .. cols(
##   ..   Cod_Div = col_double(),
##   ..   Latitud = col_double(),
##   ..   Longitud = col_double(),
##   ..   Region = col_character(),
##   ..   Departamento = col_character(),
##   ..   Municipio = col_character(),
##   ..   Fecha = col_character(),
##   ..   Hora = col_time(format = ""),
##   ..   Temperatura = col_double(),
##   ..   Velocidad_del_Viento = col_double(),
##   ..   Direccion_del_Viento = col_double(),
##   ..   Presion = col_double(),
##   ..   Punto_de_Rocio = col_double(),
##   ..   Cobertura_total_nubosa = col_double(),
##   ..   Precipitacion_mm_h = col_double(),
##   ..   Probabilidad_de_Tormenta = col_double(),
##   ..   Humedad = col_double(),
##   ..   `Pronostico ` = col_character()
##   .. )
##  - attr(*, "problems")=<externalptr>
```

```r
dim(ORI) # 4543 Filas y 18 columnas
```

```
## [1] 4543   18
```

```r
ori_mediodia <- ORI %>%
  filter(as.character(hora) == "12:00:00")

dim(ori_mediodia)
```

```
## [1] 118  18
```

2.2 Pregunta 2.

Para los registros recolectados a medio día ¿cuál es el pronóstico climático más frecuente? ¿cuál es el menos frecuente?

```r
freq_pro<- ori_mediodia %>%
  count(pronostico)

knitr::kable(freq_pro, caption = "Pronostico al medio dia")
```

Table 1: Pronostico al medio dia

pronostico	n
Despejado	3
Nublado	31
Nublado - Llovizna	4
Nublado - Lluvia	4
Parcialmente Nublado	63
Parcialmente Nublado - Llovizna	5
Parcialmente Nublado - Lluvia Fuerte	6
Parcialmente Nublado - Tormenta Ligera	2

2.3 Pregunta 3.

Clasifique las variables 1) Pronóstico, 2) Municipio, 3) Temperatura y 4) Velocidad del viento según su escala y clase.

```
clase_variables <- data.frame(
  Variable = c("Pronostico", "Municipio", "Temperatura", "Velocidad_del_viento"),
  Clase_R = sapply(ORI[, c("pronostico","municipio","temperatura","velocidad_del_viento")], class)
)

knitr::kable(clase_variables, caption = "Clase de las variables en R")
```

Table 2: Clase de las variables en R

	Variable	Clase_R
pronostico	Pronostico	character
municipio	Municipio	character
temperatura	Temperatura	numeric
velocidad_del_viento	Velocidad_del_viento	numeric

2.4 Pregunta 4.

Para los registros recolectados a medio día, describa de manera gráfica la temperatura y la velocidad del viento univariadamente a partir de un diagrama de caja. ¿Qué características observa los datos en términos de centro, localización y dispersión?.

```
ggplot(ori_mediodia, aes(y = temperatura)) +
  geom_boxplot(fill = "pink") +
  labs(
    title = "Boxplot de la temperatura a medio dia",
    y = "Temperatura"
  ) +
  theme_minimal()
```

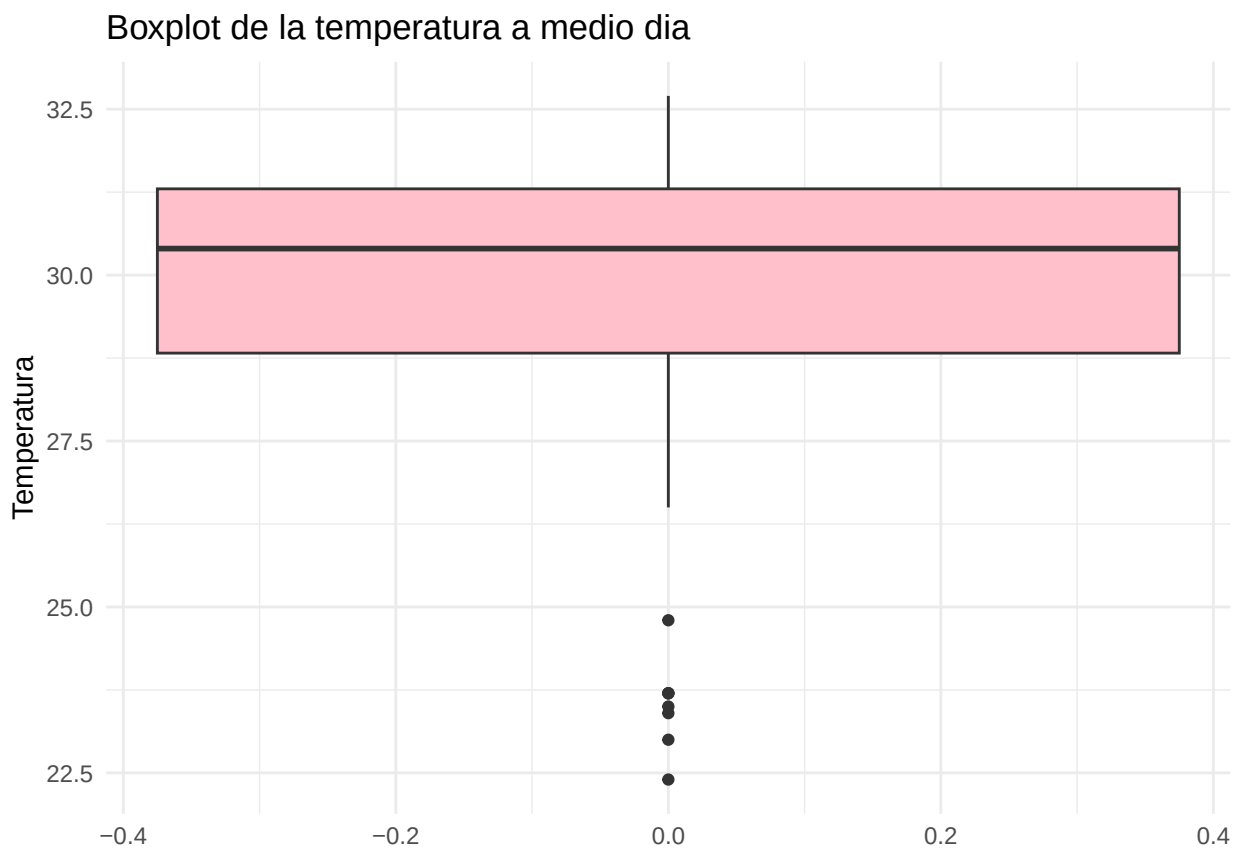

2.5 Pregunta 5.

Para los registros recolectados a medio día, describa de manera numérica mediante la función summary() la temperatura y la velocidad del viento univariadamente. ¿Concuerda su descripción con los gráficos de boxplot previamente presentados?.

```
summary(ori_mediodia$temperatura)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   22.40   28.82   30.40   29.75   31.30   32.70
```

```
summary(ori_mediodia$velocidad_del_viento)
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##   0.400   1.000   1.700   1.719   2.175   3.700
```

2.6 Pregunta 6.

Para los registros recolectados a medio día, determine si existen o no observaciones atípicas univariadas para la variables Presión y Punto de Rocio usando el diagrama de caja de Tukey. ¿cuál variable presenta mayor número de atipicidades?

```r
out_presion <- boxplot(ori_mediodia$presion, plot = FALSE)$out
out_presion
```

```
## [1] 1015.7
```

```r
out_rocio <- boxplot(ori_mediodia$punto_de_rocio, plot = FALSE)$out
out_rocio
```

```
## numeric(0)
```

2.7 Pregunta 7.

Para los registros recolectados a medio día, describa de manera gráfica la asociación entre la temperatura y velocidad del viento a partir de un diagrama de dispersión entre las variables. Añada el histograma marginal de cada variable. ¿Parecen correlacionarse las dos variables?

```r
p <- ggplot(ori_mediodia,
            aes(x = temperatura, y = velocidad_del_viento)) +
  geom_point(color = "steelblue", alpha = 0.6) +
  labs(
    title = "Relación entre temperatura y velocidad del viento a medio día",
    x = "Temperatura",
    y = "Velocidad del viento"
  ) +
  theme_minimal()

ggExtra::ggMarginal(p,
                    type = "boxplot",
                    fill = "lightblue")
```

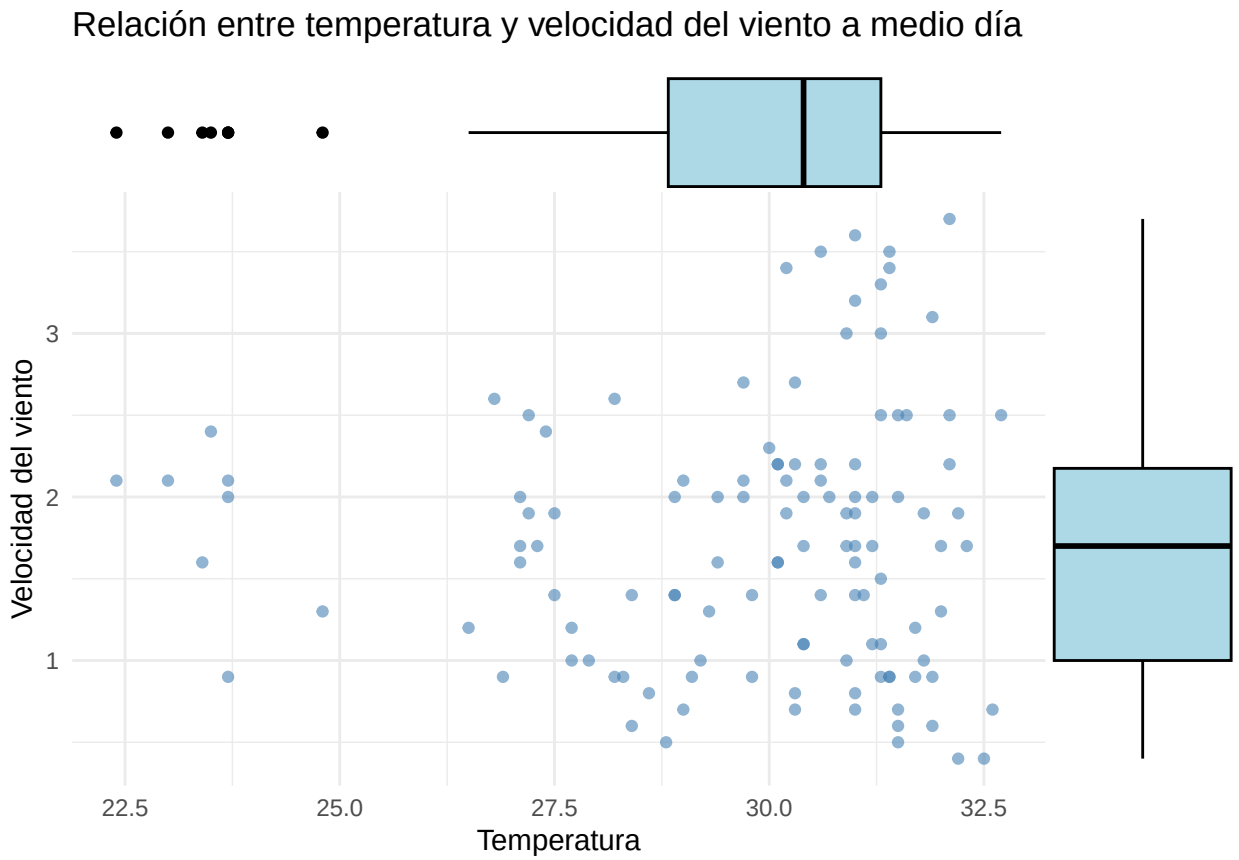

2.8 Pregunta 8.

Para los registros recolectados a medio día, describa de manera numérica la asociación entre temperatura y velocidad del viento a partir de la covarianza y el coeficiente de correlación de Pearson. ¿Parecen correlacionarse las dos variables? ¿en qué unidades se encuentran cada una de las dos medidas anteriormente mencionadas?

```
cov(ori_mediodia$temperatura,
    ori_mediodia$velocidad_del_viento)
```

```
## [1] 0.04718528
```

```
cor(ori_mediodia$temperatura,
    ori_mediodia$velocidad_del_viento)
```

```
## [1] 0.02627245
```

2.9 Pregunta 9.

Para los registros recolectados a medio día, responda. Son estos datos ¿univariados, bivariados o multivariados?

3 Parte 2. Estimación de la densidad

3.1 Pregunta 10.

Para los registros recolectados a medio día, elabore la estimación histograma de la densidad y la estimación kernel de la densidad para la variable Temperatura. ¿Podría afirmar que los datos provienen de una distribución normal?

```r
ggplot(ori_mediodia, aes(x = temperatura)) +
  geom_histogram(aes(y = ..density..),
                 bins = 30,
                 fill = "lightblue",
                 color = "black") +
  geom_density(color = "red", size = 1) +
  stat_function(fun = dnorm,
                args = list(
                  mean = mean(ori_mediodia$temperatura, na.rm = TRUE),
                  sd = sd(ori_mediodia$temperatura, na.rm = TRUE)
                ),
                color = "blue",
                linetype = "dashed") +
  labs(
    title = "Distribucion de temperatura con comparacion normal",
    x = "Temperatura",
    y = "Densidad"
  ) +
  theme_minimal()
```

```
## Warning: Using ‘size‘ aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use ‘linewidth‘ instead.
## This warning is displayed once every 8 hours.
## Call ‘lifecycle::last_lifecycle_warnings()‘ to see where this warning was
## generated.
```

```
## Warning: The dot-dot notation (‘..density..‘) was deprecated in ggplot2 3.4.0.
## i Please use ‘after_stat(density)‘ instead.
## This warning is displayed once every 8 hours.
## Call ‘lifecycle::last_lifecycle_warnings()‘ to see where this warning was
## generated.
```

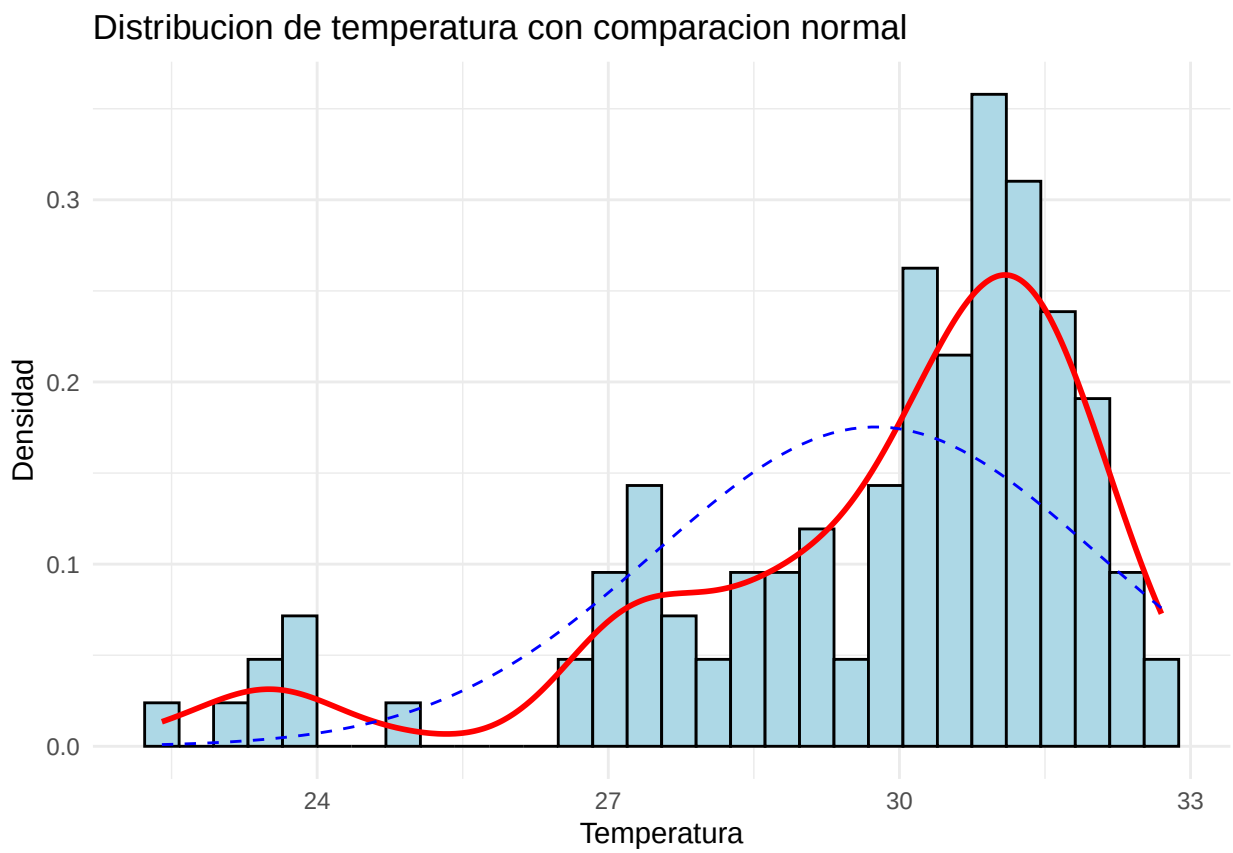

3.2 Pregunta 11.

Para los registros recolectados a medio día, elabore la estimación histograma de la densidad y la estimación kernel de la densidad para la variable Presión ¿Es la distribución estimada simétrica? explique.

```
ggplot(ori_mediodia, aes(x = presion)) +
  geom_histogram(aes(y = ..density..),
                 bins = 30,
                 fill = "lightblue",
                 color = "black") +
  geom_density(color = "red", size = 1) +
  labs(
    title = "Histograma y estimacion Kernel de la presion a medio dia",
    x = "Presion",
    y = "Densidad"
  ) +
  theme_minimal()
```

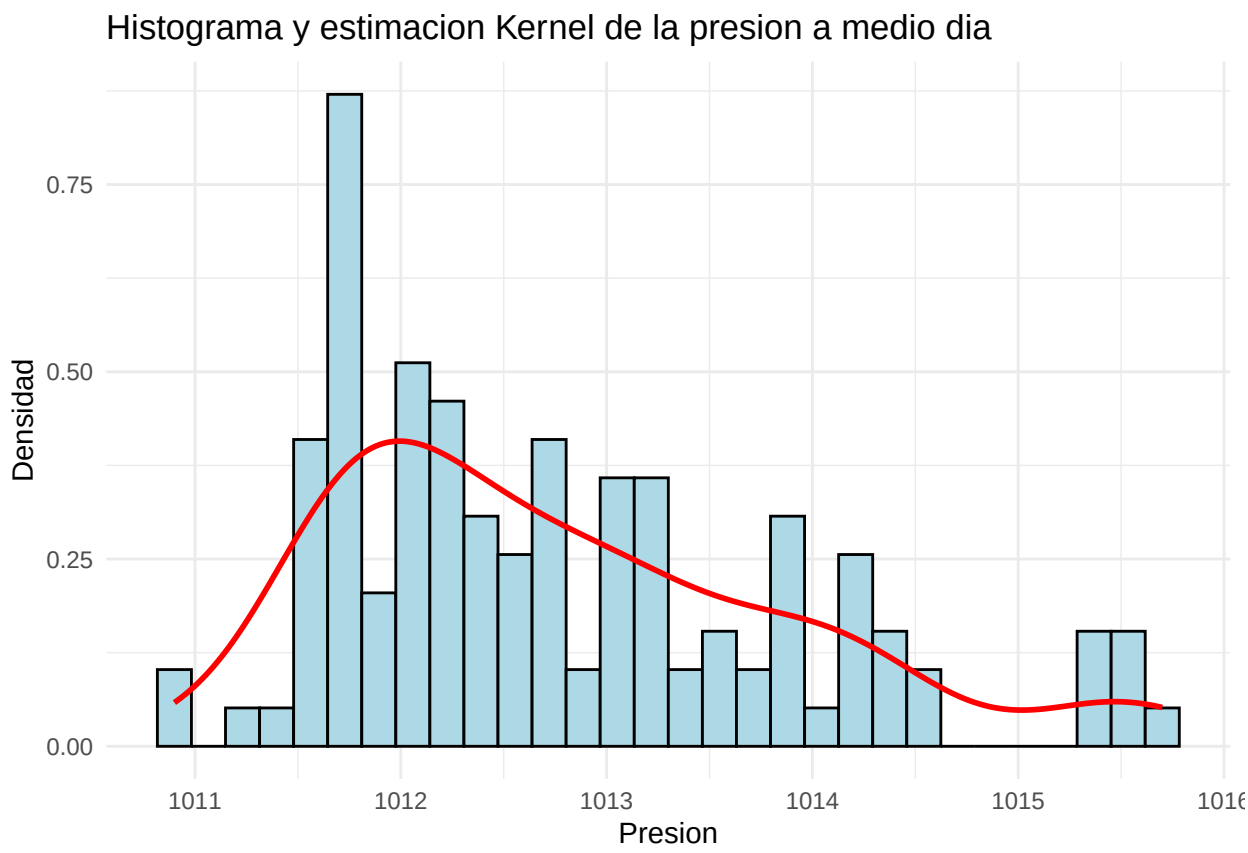

3.3 Pregunta 12.

Para los registros recolectados a medio día, elabore la estimación kernel de la densidad para la variable Velocidad del viento. Sobreponga en su gráfico la función de densidad normal con la media y desviación estándar observada en sus datos. ¿Se aproxima el modelo normal estimado a la estimación de la densidad encontrada?

```
media_viento <- mean(ori_mediodia$velocidad_del_viento, na.rm = TRUE)
sd_viento <- sd(ori_mediodia$velocidad_del_viento, na.rm = TRUE)

# Gráfico
ggplot(ori_mediodia, aes(x = velocidad_del_viento)) +
  geom_density(color = "red", size = 1) + # linea roja kernel
  stat_function(
    fun = dnorm,
    args = list(mean = media_viento, sd = sd_viento),
    color = "blue",# normal
    linetype = "dashed",
    size = 1
  ) +
  labs(
    title = "Estimacion kernel y densidad para la velocidad del viento",
    x = "Velocidad del viento",
    y = "Densidad"
```
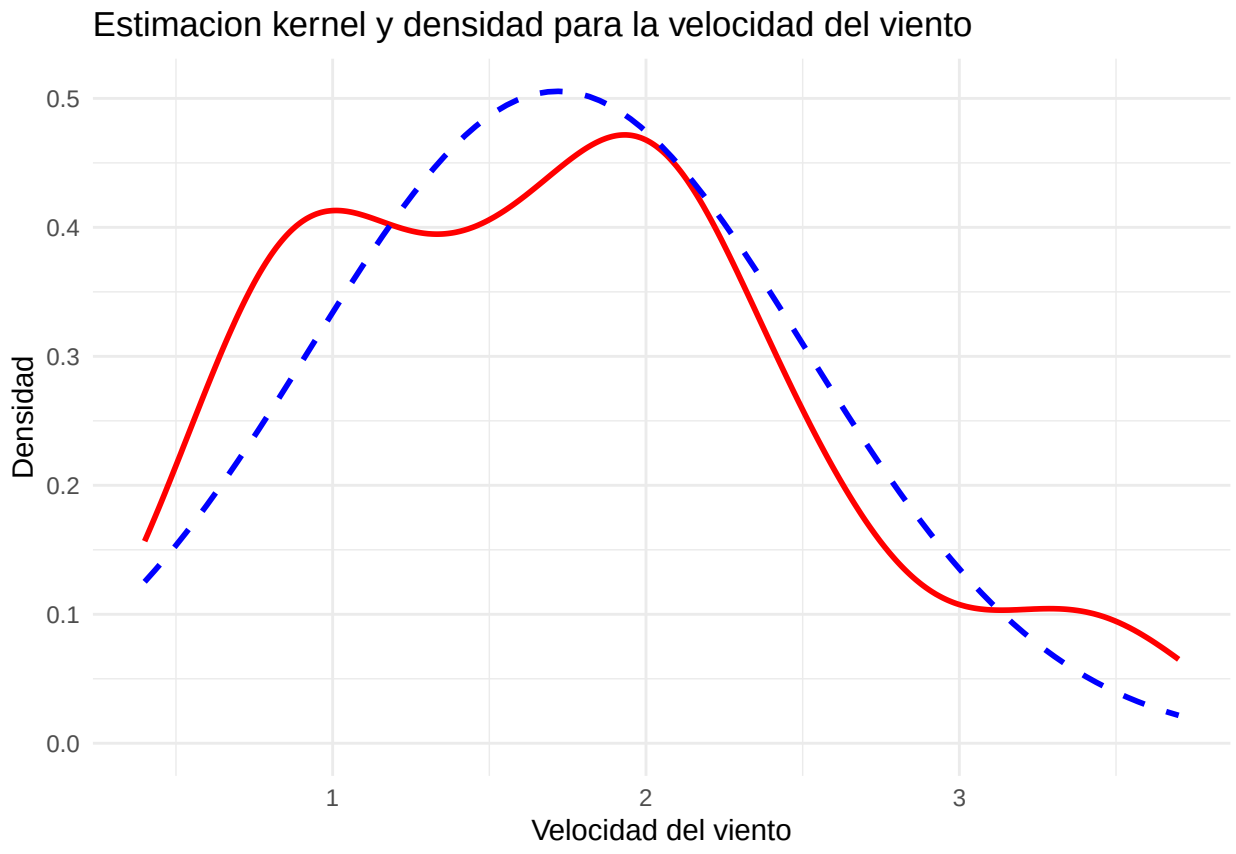
```
  ) +
  theme_minimal()
```