

Análisis Estadístico de Datos
Taller 2

Grupo 3: Vanessa Ochoa, Juan Zamora y Nilson Amaya
08 de mayo de 2026

Contents

1	Introducción	2
2	Parte 1. Normal multivariada	3
2.1	Pregunta 1.	3
3	Parte 2. ACP	4
3.1	Pregunta 2.	4
3.2	Pregunta 3.	5
3.3	Pregunta 4.	8
3.4	Pregunta 5.	10
3.5	Pregunta 6.	12
3.6	Pregunta 7.	14
4	Parte 3. Clustering	16
4.1	Pregunta 8.	16
4.2	Pregunta 9.	16
4.3	Pregunta 10.	16
4.4	Pregunta 11.	17

1 Introducción

El presente taller tiene como objetivo aplicar técnicas de análisis estadístico multivariado sobre un conjunto de datos proveniente de la U.S. Energy Information Administration (EIA), que reúne información energética de 111 países alrededor del mundo. Las variables analizadas abarcan aspectos de producción, consumo, importación y exportación de energías renovables y combustibles fósiles.

A lo largo de este documento se desarrollan los puntos propuestos, empleando el lenguaje de programación R como herramienta principal de análisis. El objetivo central es identificar patrones y relaciones entre los países estudiados que permitan caracterizar su perfil energético y agruparlos según sus similitudes en términos de comportamiento energético.

Cargue de librerías necesarias

Importación base de datos

```
data1 <- read.csv("taller_2/input/datos_taller_02.csv",
                  row.names=1, sep=";")

names(data1)

## [1] "Bunker_fuel_consumption_TBPD"
## [2] "Bunker_residual_fuel_oil_consumption_TBPD"
## [3] "Crude_oil_including_lease_condensate_exports_TBPD"
## [4] "Crude_oil_including_lease_condensate_imports_TBPD"
## [5] "Crude_oil_including_lease_condensate_production_TBPD"
## [6] "Crude_oil_including_lease_condensate_reserves_BB"
## [7] "Distillate_fuel_oil_consumption_TBPD"
## [8] "Distillate_fuel_oil_production_TBPD"
## [9] "Jet_fuel_consumption_TBPD"
## [10] "Jet_fuel_production_TBPD"
## [11] "Kerosene_consumption_TBPD"
## [12] "Kerosene_production_TBPD"
## [13] "Liquefied_petroleum_gases_.LPG._consumption_TBPD"
## [14] "Liquefied_petroleum_gases_.LPG._production_TBPD"
## [15] "Motor_gasoline_consumption_TBPD"
## [16] "Motor_gasoline_production_TBPD"
## [17] "Natural_gas_plant_liquids_production_TBPD"
## [18] "Other_liquids_production_TBPD"
## [19] "Other_refined_products_consumption_TBPD"
## [20] "Other_refined_products_production_TBPD"
## [21] "Petroleum_and_other_liquids_CO2_emissions_MMTCD"
## [22] "Petroleum_and_other_liquids_consumption_TBPD"
## [23] "Petroleum_and_other_liquids_production_TBPD"
## [24] "Refined_petroleum_products_consumption_TBPD"
## [25] "Refined_petroleum_products_production_TBPD"
## [26] "Refinery_processing_gain_TBPD"
## [27] "Residual_fuel_oil_consumption_TBPD"
## [28] "Residual_fuel_oil_production_TBPD"
## [29] "Biomass_and_waste_electricity_installed_capacity_MK"
## [30] "Biomass_and_waste_electricity_net_generation_BKWH"
## [31] "Electricity_distribution_losses_BKWH"
## [32] "Electricity_exports_BKWH"
## [33] "Electricity_imports_BKWH"
## [34] "Electricity_installed_capacity_MK"
```

```
## [35] "Electricity_net_consumption_BKWH"
## [36] "Electricity_net_generation_BKWH"
## [37] "Electricity_net_imports_BKWH"
## [38] "Fossil_fuels_electricity_installed_capacity_MK"
## [39] "Fossil_fuels_electricity_net_generation_BKWH"
## [40] "Geothermal_electricity_installed_capacity_MK"
## [41] "Geothermal_electricity_net_generation_BKWH"
## [42] "Hydroelectric_pumped_storage_electricity_installed_capacity_MK"
## [43] "Hydroelectric_pumped_storage_electricity_net_generation_BKWH"
## [44] "Hydroelectricity_installed_capacity_MK"
## [45] "Hydroelectricity_net_generation_BKWH"
## [46] "Non.hydro_renewable_electricity_installed_capacity_MK"
## [47] "Non.hydro_renewable_electricity_net_generation_BKWH"
## [48] "Nuclear_electricity_installed_capacity_MK"
## [49] "Nuclear_electricity_net_generation_BKWH"
## [50] "Renewable_electricity_installed_capacity_MK"
## [51] "Renewable_electricity_net_generation_BKWH"
## [52] "Solar_electricity_installed_capacity_MK"
## [53] "Solar_electricity_net_generation_BKWH"
## [54] "Tide_and_wave_electricity_installed_capacity_MK"
## [55] "Tide_and_wave_electricity_net_generation_BKWH"
## [56] "Wind_electricity_installed_capacity_MK"
## [57] "Wind_electricity_net_generation_BKWH"
```

```
dim(data1)
```

```
## [1] 111 57
```

Al revisar la base de datos se observa que esta cuenta con 111 países como unidades de estudio y 57 variables energéticas. Estas variables se encuentran organizadas en dos grandes grupos: el primero relacionado con combustibles fósiles, que incluye información sobre consumo, producción, exportación, importación y reservas de petróleo crudo, gasolina, diésel, queroseno, GLP y fuel oil, expresadas principalmente en miles de barriles por día (TBDP); y el segundo relacionado con electricidad, que contiene variables de capacidad instalada y generación neta clasificadas por fuente de energía, tanto renovables (solar, eólica, hidroeléctrica, geotérmica, biomasa y mareomotriz) como no renovables (combustibles fósiles y nuclear), expresadas en megakilovatios (MK) y billones de kilovatios-hora (BKWH).

2 Parte 1. Normal multivariada

2.1 Pregunta 1.

Encuentre la estimación del vector de medias y la matriz de varianzas y covarianzas para 5 variables de su interés del conjunto de datos.

```
vars <- c("Bunker_fuel_consumption_TBPD",
          "Crude_oil_including_lease_condensate_exports_TBPD",
          "Petroleum_and_other_liquids_CO2_emissions_MMTCD",
          "Renewable_electricity_net_generation_BKWH",
          "Solar_electricity_installed_capacity_MK")

data_sel <- data1[, vars]
```

```
colnames(data_sel) <- c("Bunker_fuel", "Exp_petroleo_crudo",
                       "Emis_CO2_petroleo", "Gen_elec_renovable",
                       "Cap_solar_instalada")
# Vector de medias
vector_medias <- colMeans(data_sel, na.rm = TRUE)
```

Table 1: Vector de medias

	vector_medias
Bunker_fuel	46.01
Exp_petroleo_crudo	361.56
Emis_CO2_petroleo	101.04
Gen_elec_renovable	44.77
Cap_solar_instalada	1.34

```
# Matriz de covarianzas
matriz_cov <- cov(data_sel, use = "complete.obs")
```

Table 2: Matriz de varianzas y covarianzas

	Bunker_fuel	Exp_petroleo_crudo	Emis_CO2_petroleo	Gen_elec_renovable	Cap_solar_instalada
Bunker_fuel	15329.11	24305.07	20055.14	6671.58	171.84
Exp_petroleo_crudo	24305.07	907731.96	41266.49	8667.85	-342.95
Emis_CO2_petroleo	20055.14	41266.49	68607.05	29088.28	789.37
Gen_elec_renovable	6671.58	8667.85	29088.28	20864.46	442.89
Cap_solar_instalada	171.84	-342.95	789.37	442.89	18.08

3 Parte 2. ACP

3.1 Pregunta 2.

Realice un análisis descriptivo univariado y bivariado del conjunto de datos. Considere nuevamente las mismas 5 variables de su interés para este punto.

Ayuda: La función `ggpairs()` puede serle de utilidad para ver las asociaciones dos a dos entre las variables de una manera sencilla.


```
# Análisis univariado
summary(data_sel)
```

```
##   Bunker_fuel   Exp_petroleo_crudo Emis_CO2_petroleo Gen_elec_renovable
##   Min.    : 0.00   Min.    : 0.0     Min.    : 2.30   Min.    : 0.00
##   1st Qu.: 2.70   1st Qu.: 0.0     1st Qu.: 9.65   1st Qu.: 1.50
##   Median : 8.40   Median : 8.5     Median : 26.00  Median : 8.30
##   Mean   : 46.01  Mean   : 361.6    Mean   : 101.04 Mean   : 44.77
##   3rd Qu.: 32.00  3rd Qu.: 220.5    3rd Qu.: 94.50  3rd Qu.: 26.50
##   Max.   :924.00  Max.   :7120.0    Max.   :2263.00 Max.   :1287.00
##   Cap_solar_instalada
##   Min.    : 0.000
##   1st Qu.: 0.000
```

```
## Median : 0.000
## Mean   : 1.339
## 3rd Qu.: 0.300
## Max.    :28.000
```

El análisis descriptivo revela que variables como las exportaciones de petróleo crudo y las emisiones de CO2 presentan medias muy superiores a sus medianas, lo que indica distribuciones asimétricas donde unos pocos países concentran valores extremadamente altos. La capacidad solar instalada es la variable con menor variabilidad, reflejando que la energía solar aún tiene un desarrollo limitado en la mayoría de los países analizados.

```
# Análisis bivariado
ggpairs(data_sel,
        title = "Análisis bivariado de variables energeticas")
```



El análisis bivariado muestra que las emisiones de CO2 presentan correlaciones positivas y significativas con la generación eléctrica renovable (0.769) y la capacidad solar instalada (0.709), lo que indica que los países con mayor actividad energética en general tienden a desarrollar también más energías renovables.

El bunker fuel muestra correlaciones moderadas con las demás variables. Por su parte, las exportaciones de petróleo crudo no presentan correlaciones significativas con la generación renovable ni con la capacidad solar. En los diagramas de dispersión se aprecia que todas las variables presentan distribuciones muy asimétricas, con la mayoría de países concentrados en valores bajos y unos pocos outliers con valores extremos.

3.2 Pregunta 3.

El conjunto de datos incluye 57 variables, analizarlas de forma individual podría representar un gasto computacional y de tiempo bastante agotador; por lo cual una técnica de reducción de dimensionalidad sería ideal. Ejecute un ACP sobre estos datos, compare la contribución de las variables sobre el primer plano factorial de un ACP normado (escalado) y uno sin normalizar (sin escalar).

```

acp_sin <- prcomp(data1, rank. = 2)

acp_con <- prcomp(data1, scale. = TRUE, rank. = 2)

# % varianza explicada por los 2 primeros CPs
sin_esc = summary(acp_sin)$importance[2, 1:2]
con_esc = summary(acp_con)$importance[2, 1:2]
rbind(sin_escala=round(sin_esc,3), con_escala=round(con_esc,3))

##           PC1    PC2
## sin_escala 0.829 0.143
## con_escala 0.620 0.077

```

Al comparar la varianza explicada por los dos primeros componentes principales, se observa que el ACP sin escalar concentra el 82.9% de la varianza en el primer componente, lo que indica que una o pocas variables con magnitudes muy grandes están dominando el análisis. En contraste, el ACP escalado distribuye mejor la información, explicando un 62% en el primer componente y un 7.7% en el segundo. Esto confirma que el ACP normado es más adecuado para este conjunto de datos, ya que al estandarizar las variables permite que todas contribuyan de manera equitativa al análisis, independientemente de sus unidades y escalas originales.

Table 3: Cargas ACP escalado

	PC1	PC2
Bunker_fuel_consumption_TBPD	0.101	0.154
Bunker_residual_fuel_oil_consumption_TBPD	0.050	0.081
Crude_oil_including_lease_condensate_exports_TBPD	0.021	0.280
Crude_oil_including_lease_condensate_imports_TBPD	0.156	-0.089
Crude_oil_including_lease_condensate_production_TBPD	0.101	0.273
Crude_oil_including_lease_condensate_reserves_BB	0.026	0.220
Distillate_fuel_oil_consumption_TBPD	0.165	-0.022
Distillate_fuel_oil_production_TBPD	0.166	0.021
Jet_fuel_consumption_TBPD	0.156	0.116
Jet_fuel_production_TBPD	0.157	0.101
Kerosene_consumption_TBPD	0.043	-0.093
Kerosene_production_TBPD	0.045	-0.026
Liquefied_petroleum_gases_LPG_consumption_TBPD	0.159	0.040
Liquefied_petroleum_gases_LPG_production_TBPD	0.152	-0.022
Motor_gasoline_consumption_TBPD	0.152	0.138
Motor_gasoline_production_TBPD	0.151	0.136
Natural_gas_plant_liquids_production_TBPD	0.118	0.308
Other_liquids_production_TBPD	0.147	0.083
Other_refined_products_consumption_TBPD	0.161	-0.003
Other_refined_products_production_TBPD	0.161	-0.039
Petroleum_and_other_liquids_CO2_emissions_MMTCD	0.166	0.059
Petroleum_and_other_liquids_consumption_TBPD	0.166	0.062
Petroleum_and_other_liquids_production_TBPD	0.117	0.279
Refined_petroleum_products_consumption_TBPD	0.166	0.062
Refined_petroleum_products_production_TBPD	0.165	0.075
Refinery_processing_gain_TBPD	0.147	0.126
Residual_fuel_oil_consumption_TBPD	0.089	0.043
Residual_fuel_oil_production_TBPD	0.083	0.168
Biomass_and_waste_electricity_installed_capacity_MK	0.137	0.018
Biomass_and_waste_electricity_net_generation_BKWH	0.151	-0.058
Electricity_distribution_losses_BKWH	0.151	-0.071
Electricity_exports_BKWH	0.040	-0.082
Electricity_imports_BKWH	0.091	0.061
Electricity_installed_capacity_MK	0.162	-0.096

	PC1	PC2
Electricity_net_consumption_BKWH	0.161	-0.097
Electricity_net_generation_BKWH	0.161	-0.098
Electricity_net_imports_BKWH	0.040	0.124
Fossil_fuels_electricity_installed_capacity_MK	0.161	-0.074
Fossil_fuels_electricity_net_generation_BKWH	0.157	-0.106
Geothermal_electricity_installed_capacity_MK	0.085	0.155
Geothermal_electricity_net_generation_BKWH	0.086	0.161
Hydroelectric_pumped_storage_electricity_installed_capacity_MK	0.133	-0.130
Hydroelectric_pumped_storage_electricity_net_generation_BKWH	-0.152	0.048
Hydroelectricity_installed_capacity_MK	0.131	-0.195
Hydroelectricity_net_generation_BKWH	0.125	-0.198
Non.hydro_renewable_electricity_installed_capacity_MK	0.156	-0.151
Non.hydro_renewable_electricity_net_generation_BKWH	0.162	-0.067
Nuclear_electricity_installed_capacity_MK	0.128	0.107
Nuclear_electricity_net_generation_BKWH	0.131	0.122
Renewable_electricity_installed_capacity_MK	0.145	-0.187
Renewable_electricity_net_generation_BKWH	0.142	-0.174
Solar_electricity_installed_capacity_MK	0.130	-0.192
Solar_electricity_net_generation_BKWH	0.138	-0.137
Tide_and_wave_electricity_installed_capacity_MK	0.018	-0.081
Tide_and_wave_electricity_net_generation_BKWH	0.018	-0.086
Wind_electricity_installed_capacity_MK	0.151	-0.158
Wind_electricity_net_generation_BKWH	0.159	-0.067

El PC1 recibe contribuciones similares de casi todas las variables (entre 0.10 y 0.17), representando un factor general de actividad energética del país. El PC2 diferencia entre países con perfil de combustibles fósiles, con cargas positivas en producción de gas natural (0.308) y reservas de petróleo (0.220), frente a países con mayor desarrollo renovable, con cargas negativas en generación hidroeléctrica (-0.195) y capacidad solar (-0.192).

Table 4: Cargas ACP sin escalas

	PC1	PC2
Bunker_fuel_consumption_TBPD	0.016	0.000
Bunker_residual_fuel_oil_consumption_TBPD	0.005	-0.001
Crude_oil_including_lease_condensate_exports_TBPD	0.066	0.423
Crude_oil_including_lease_condensate_imports_TBPD	0.178	-0.243
Crude_oil_including_lease_condensate_production_TBPD	0.276	0.539
Crude_oil_including_lease_condensate_reserves_BB	0.003	0.015
Distillate_fuel_oil_consumption_TBPD	0.104	-0.064
Distillate_fuel_oil_production_TBPD	0.124	-0.062
Jet_fuel_consumption_TBPD	0.029	-0.016
Jet_fuel_production_TBPD	0.032	-0.019
Kerosene_consumption_TBPD	0.001	-0.003
Kerosene_production_TBPD	0.002	0.000
Liquefied_petroleum_gases_LPG_consumption_TBPD	0.037	-0.010
Liquefied_petroleum_gases_LPG_production_TBPD	0.021	-0.006
Motor_gasoline_consumption_TBPD	0.169	-0.081
Motor_gasoline_production_TBPD	0.178	-0.099
Natural_gas_plant_liquids_production_TBPD	0.057	0.042
Other_liquids_production_TBPD	0.025	-0.016
Other_refined_products_consumption_TBPD	0.090	-0.028
Other_refined_products_production_TBPD	0.076	-0.040
Petroleum_and_other_liquids_CO2_emissions_MMTCD	0.053	-0.024
Petroleum_and_other_liquids_consumption_TBPD	0.443	-0.199
Petroleum_and_other_liquids_production_TBPD	0.377	0.550

	PC1	PC2
Refined_petroleum_products_consumption_TBPD	0.443	-0.199
Refined_petroleum_products_production_TBPD	0.453	-0.185
Refinery_processing_gain_TBPD	0.019	-0.014
Residual_fuel_oil_consumption_TBPD	0.013	0.005
Residual_fuel_oil_production_TBPD	0.022	0.040
Biomass_and_waste_electricity_installed_capacity_MK	0.000	0.000
Biomass_and_waste_electricity_net_generation_BKWH	0.002	-0.002
Electricity_distribution_losses_BKWH	0.008	-0.005
Electricity_exports_BKWH	0.000	0.000
Electricity_imports_BKWH	0.001	-0.001
Electricity_installed_capacity_MK	0.031	-0.025
Electricity_net_consumption_BKWH	0.112	-0.092
Electricity_net_generation_BKWH	0.119	-0.096
Electricity_net_imports_BKWH	0.001	-0.001
Fossil_fuels_electricity_installed_capacity_MK	0.021	-0.016
Fossil_fuels_electricity_net_generation_BKWH	0.083	-0.070
Geothermal_electricity_installed_capacity_MK	0.000	0.000
Geothermal_electricity_net_generation_BKWH	0.000	0.000
Hydroelectric_pumped_storage_electricity_installed_capacity_MK	0.001	-0.001
Hydroelectric_pumped_storage_electricity_net_generation_BKWH	0.000	0.000
Hydroelectricity_installed_capacity_MK	0.004	-0.003
Hydroelectricity_net_generation_BKWH	0.015	-0.011
Non.hydro_renewable_electricity_installed_capacity_MK	0.003	-0.003
Non.hydro_renewable_electricity_net_generation_BKWH	0.007	-0.008
Nuclear_electricity_installed_capacity_MK	0.002	-0.001
Nuclear_electricity_net_generation_BKWH	0.014	-0.008
Renewable_electricity_installed_capacity_MK	0.007	-0.007
Renewable_electricity_net_generation_BKWH	0.022	-0.018
Solar_electricity_installed_capacity_MK	0.001	-0.001
Solar_electricity_net_generation_BKWH	0.001	-0.001
Tide_and_wave_electricity_installed_capacity_MK	0.000	0.000
Tide_and_wave_electricity_net_generation_BKWH	0.000	0.000
Wind_electricity_installed_capacity_MK	0.002	-0.002
Wind_electricity_net_generation_BKWH	0.004	-0.004

En el ACP sin escalar, el PC1 está dominado por variables de producción y consumo de petróleo refinado (cargas entre 0.37 y 0.45), mientras que las variables eléctricas tienen cargas cercanas a cero, lo que evidencia que las variables con mayores magnitudes absorben casi toda la varianza. El PC2 contrasta la producción de petróleo crudo (0.539) frente a las importaciones (-0.243) y el consumo de productos refinados (-0.199). Esto confirma que sin escalar, el análisis está sesgado por las unidades de medida y no refleja adecuadamente la estructura real de los datos.

3.3 Pregunta 4.

Una vez calculado el PCA normado, ¿qué número de componentes principales deberíamos seleccionar? ¿Bajo que criterio seleccionó este número de componentes?

```
acp_con <- prcomp(data1, scale. = TRUE)
round(summary(acp_con)$importance, 3)
```


```
##          PC1  PC2  PC3  PC4  PC5  PC6  PC7  PC8  PC9
## Standard deviation  5.943 2.100 2.000 1.645 1.567 1.367 1.143 1.056 0.950
## Proportion of Variance 0.620 0.077 0.070 0.047 0.043 0.033 0.023 0.020 0.016
## Cumulative Proportion 0.620 0.697 0.767 0.815 0.858 0.890 0.913 0.933 0.949
##          PC10 PC11 PC12 PC13 PC14 PC15 PC16 PC17 PC18
```



```
## Standard deviation      0.870 0.739 0.552 0.524 0.456 0.437 0.365 0.351 0.262
## Proportion of Variance 0.013 0.010 0.005 0.005 0.004 0.003 0.002 0.002 0.001
## Cumulative Proportion 0.962 0.972 0.977 0.982 0.985 0.989 0.991 0.993 0.994
##          PC19  PC20  PC21  PC22  PC23  PC24  PC25  PC26  PC27
## Standard deviation      0.241 0.223 0.194 0.178 0.157 0.147 0.128 0.118 0.113
## Proportion of Variance 0.001 0.001 0.001 0.001 0.000 0.000 0.000 0.000 0.000
## Cumulative Proportion 0.995 0.996 0.997 0.998 0.998 0.998 0.999 0.999 0.999
##          PC28  PC29  PC30  PC31  PC32  PC33  PC34  PC35  PC36
## Standard deviation      0.099 0.093 0.085 0.077 0.074 0.067 0.048 0.041 0.039
## Proportion of Variance 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## Cumulative Proportion 0.999 0.999 1.000 1.000 1.000 1.000 1.000 1.000 1.000
##          PC37  PC38  PC39  PC40  PC41  PC42  PC43  PC44  PC45
## Standard deviation      0.031 0.027 0.025 0.021 0.015 0.013 0.009 0.005 0.005
## Proportion of Variance 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000 0.000
## Cumulative Proportion 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000 1.000
##          PC46  PC47  PC48  PC49  PC50  PC51  PC52  PC53  PC54  PC55
## Standard deviation      0.004 0.002 0.002 0.001 0.001 0.001      0      0      0      0
## Proportion of Variance 0.000 0.000 0.000 0.000 0.000 0.000      0      0      0      0
## Cumulative Proportion 1.000 1.000 1.000 1.000 1.000 1.000      1      1      1      1
##          PC56  PC57
## Standard deviation      0      0
## Proportion of Variance 0      0
## Cumulative Proportion 1      1
```

```
screepLOT(acp_con, col="blue", pch=16,
type="lines", cex=1.5, lwd=2,
main="ScreepLOT")
```

ScreepLOT



Con base en el screeplot se observa una caída drástica en la varianza explicada a partir del segundo componente, estabilizándose desde el tercero. Aplicando conjuntamente el criterio del codo y la varianza acumulada, se seleccionan 3 componentes principales, los cuales explican el 76.7% de la variabilidad total de los datos, siendo un número suficiente para representar la estructura del conjunto sin perder demasiada información.

3.4 Pregunta 5.


Analice la representación de las variables originales sobre las dos primeras componentes en el primer plano factorial. ¿Que conclusiones podemos sacar de este análisis?

```
acp_con2 <- acp_con
rownames(acp_con2$rotation) <- paste0("V", 1:57)

fviz_pca_var(acp_con2, axes=c(1,2),
             col.var="contrib",
             gradient.cols=c("steelblue","gold","tomato"),
             select.var=list(contrib=30),
             repel=TRUE)


## Warning: Using 'size' aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use 'linewidth' instead.
## i The deprecated feature was likely used in the ggpubr package.
##   Please report the issue at <https://github.com/kassambara/ggpubr/issues>.
## This warning is displayed once per session.
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was
## generated.

## Warning: 'aes_string()' was deprecated in ggplot2 3.0.0.
## i Please use tidy evaluation idioms with 'aes()'.
## i See also 'vignette("ggplot2-in-packages")' for more information.
## i The deprecated feature was likely used in the factoextra package.
##   Please report the issue at <https://github.com/kassambara/factoextra/issues>.
## This warning is displayed once per session.
## Call 'lifecycle::last_lifecycle_warnings()' to see where this warning was
## generated.
```



En el plano factorial PC1-PC2 se observa que la gran mayoría de variables apuntan hacia la derecha sobre el PC1, lo que indica que este componente representa un factor general de actividad energética: países con mayor producción, consumo y generación de energía tienen valores altos en PC1. La variable V43 es la única que apunta en dirección opuesta, sugiriendo que se comporta de manera contraria al resto. En el PC2 se aprecia cierta diferenciación entre variables que apuntan hacia arriba (V17, V15, V9) y las que apuntan hacia abajo (V46, V50, V56), lo que podría reflejar un contraste entre tipos de energía. Las variables con mayor contribución (en rojo) son las que más determinan la construcción del primer plano factorial.

```
fviz_pca_var(acp_con2, axes=c(2,3),
  col.var="contrib",
  gradient.cols=c("steelblue","gold","tomato"),
  select.var=list(contrib=30),
  repel=TRUE)
```




En el plano factorial PC2-PC3 se observa una mayor dispersión de las variables en todas las direcciones, lo que indica que estos componentes capturan patrones más específicos que el PC1. En el PC2 se distinguen variables que apuntan hacia la derecha (V17, V16, V15, V9) frente a las que apuntan hacia la izquierda (V52, V53, V42), sugiriendo un contraste entre dos grupos de variables energéticas. En el PC3 se diferencian variables con carga positiva (V40, V41, V37) frente a las de carga negativa (V3, V6, V5), las cuales tienen además la mayor contribución al plano (en rojo y naranja). A diferencia del plano PC1-PC2, aquí las variables se distribuyen más equilibradamente, lo que permite identificar relaciones más específicas entre distintos tipos de energía.

3.5 Pregunta 6.


Ahora examine con detenimiento el mapa de individuos sobre los planos factoriales que conforman las componentes (1,2) y (2,3). ¿Qué conclusiones puede sacar según la cercanía de algunas UE?

```
fviz_pca_ind(acp_con, axes=c(1,2),
             col.ind=data1$Petroleum_and_other_liquids_consumption_TBPD,
             gradient.cols=c("tomato","gold","steelblue"),
             repel=TRUE, label="all",
             labels=2)
```



El mapa de individuos sobre el plano PC1-PC2 muestra que la mayoría de los 111 países se concentran cerca del origen, indicando perfiles energéticos similares y moderados. Sin embargo, destacan claramente dos países atípicos: Estados Unidos y China, que se ubican muy alejados del resto sobre el PC1, reflejando su altísimo consumo de petróleo y actividad energética en general. China además se separa ligeramente en el PC2. El color azul de estos países confirma que son los de mayor consumo, mientras que la gran masa de países en rojo presenta niveles de consumo relativamente bajos y homogéneos entre sí.

```
fviz_pca_ind(acp_con, axes=c(2,3),
  col.ind=data1$Petroleum_and_other_liquids_consumption_TBPD,
  gradient.cols=c("tomato","gold","steelblue"),
  repel=TRUE, label="all",
  labels=2)
```



En el plano PC2-PC3 se observa una mayor separación entre países. China se destaca hacia la izquierda, mientras que Arabia Saudita y Rusia aparecen en el cuadrante inferior derecho, lo que refleja su condición de grandes productores de petróleo. Los países europeos tienden a agruparse en la parte superior, sugiriendo perfiles energéticos similares entre ellos. Estados Unidos nuevamente aparece alejado del resto.


3.6 Pregunta 7.

Como hemos observado en clase, el ACP es una técnica bastante sensible a datos atípicos, ejecute nuevamente el ACP retirando del conjunto de datos a Estados Unidos, China, Arabia Saudita y Rusia. ¿En que cambia el ACP al excluir estos países?. ¿Se perciben clusters de países con mayor claridad?. Calcule únicamente el ACP normado.

```
data2 <- data1 %>% filter(!rownames(data1) %in% c("UnitedStates", "China",
                                                  "SaudiArabia", "Russia"))


acp_con_sin <- prcomp(data2, scale.=TRUE)

fviz_pca_ind(acp_con_sin, axes=c(1,2),
              col.ind=data2$Petroleum_and_other_liquids_consumption_TBDP,
              gradient.cols=c("tomato","gold","steelblue"),
              repel=TRUE, label="all",
              labels=2)
```



Al retirar los cuatro países atípicos, el ACP cambia notablemente. El PC1 pasa de explicar el 62% a un 48.9%, y el PC2 sube al 10.2%. En el gráfico se perciben con mayor claridad algunos grupos: Japón, India, Canadá y Brasil se separan del resto hacia la derecha con consumos moderados-altos, mientras que países como Francia, Italia y Corea del Sur se agrupan en la parte superior. Los países Kuwait, Irán y Venezuela aparecen en el cuadrante inferior derecho. La gran mayoría de países africanos y latinoamericanos siguen concentrados cerca del origen con consumos bajos.

```
fviz_pca_ind(acp_con_sin, axes=c(2,3),
  col.ind=data2$Petroleum_and_other_liquids_consumption_TBPD,
  gradient.cols=c("tomato","gold","steelblue"),
  repel=TRUE, label="all",
  labels=2)
```



En el plano PC2-PC3 se observan grupos más definidos. Japón se separa claramente hacia arriba, mientras que Canadá y Brasil aparecen en el cuadrante inferior izquierdo, y Francia en el inferior derecho, sugiriendo perfiles energéticos particulares en cada caso. Los países como Irán, Emiratos Árabes, Irak y Venezuela, se agrupan hacia la izquierda, reflejando su perfil productor de petróleo. En general, al retirar los países atípicos la dispersión mejora y algunos grupos son más identificables, aunque dado el alto número de países (107) el gráfico sigue siendo denso y difícil de interpretar en su totalidad.

4 Parte 3. Clustering

4.1 Pregunta 8.

De acuerdo a lo aprendido en la clase de agrupamiento, utilice el primer plano factorial para determinar de manera aproximada el número de grupos en el análisis. ¿Cuántos clusters espera que existan en el conjunto de datos?

4.2 Pregunta 9.

Mediante el método de reducción de varianza explicada, determine un número fijo de clusters para su análisis. No tiene que ser el mismo número que el elegido por su compañero, recuerde que ninguno conoce las etiquetas reales de los grupos de los países.

4.3 Pregunta 10.

Determine mediante k-means y aglomeración jerárquica (usando enlace promedio) la clasificación en grupos para los países de estudio. Considere todas las variables de estudio ¿son diferentes los resultados de los dos análisis cluster?

4.4 Pregunta 11.

Grafique mediante boxplot la distribución de las 5 variables seleccionadas en el punto 2 diferenciando por los grupos encontrados mediante k-means (es decir, obtenga un boxplot por variable y por grupo: si por ejemplo k-means indica un total de 3 grupos, realice 3 boxplots, uno por grupo, para cada una de las 5 variables). ¿Observa diferencias importantes entre las distribuciones por grupos de la misma variable?